

TransE:

受到 13 年的 word2vec 启发，发现词向量空间存在平移不变现象，因此 TransE 作者将知识库中的关系看做实体间某种平移向量。

而在实际学习过程中，为了增强 embedding 的区分能力，采用最大间隔方法，最大化合法三元组与错误三元组得分之间的间隔距离。其中错误三元组是将每个三元组的 $h \setminus r \setminus t$ 之一随即替换得到的。

TransH:

提出让一个实体在不同的关系下拥有不同的表示，也就是将关系映射到另一个空间中，然后将头尾节点映射到关系平面上，只要保证头结点和尾节点在关系平面上的投影在一条直线上即可。不同于 TransE 模型随机替换 head 和 tail 节点作为负例的方法，本文分别赋给头结点和尾节点一个采样概率，即对于多对一的关系，替换尾节点，对于一对多的关系，替换头节点。

TransR:

TransE 和 TransH 都假设实体和关系嵌入在相同的空间中。然而，一个实体是多种属性的综合体，不同关系对应实体的不同属性，即头尾节点和关系可能不在一个向量空间中。对于每个元组 (h, r, t) ，首先将实体空间内的实体通过 M_r 矩阵投影到关系 r 所在的空间内，得到 hr 和 tr ，然后使 $hr + t \approx tr$ 。

NTN:

张量神经网络模型，基本思想是用双线性张量取代传统神经网络中的线性变换层，在不同维度下将头尾实体向量联系起来。引入张量操作，虽然可以更精确的刻画语义关系，但是计算复杂度较高。

Hole:

全息表示模型，提出使用头尾实体向量的循环相关操作来表示实体对，也就是张量乘法的一种形式。(NTN 是张量的连接，Hole 是张量的相乘)

DisMult:

发现利用双线性公式学习到的嵌入特别善于捕获关系语义，关系的组合，也就是将实体和关系进行矩阵乘法作为特征。

Complex:

将实体和关系表示为复数向量，每一个复数向量，然后定义一个打分函数，正确的三元组得分函数值会较高而不正确的三元组得分函数的值会较低。

R-GCN:

GCN 提供了一个为图节点表示学习的卷积神经网络框架,输入的直接是图的邻接矩阵, R-GCN 提供了一个三元组自编码解码的评分方法,使它更适用于知识图谱。

链接预测:

是给定一个缺失头实体或尾实体的元组,预测出相应的头尾实体。